★ 2026 企业级高安全与离线智能体标杆工程

AI-Client 离线智能体工作站

全离线自主可控 · 原生 DrawingML 矢量演示文稿 · 音画同步口播视频 · 国产信

创全生态适配

产品功能全景深度剖析与工程实现技术白皮书（Release v2.0）

研发机构： AI-Client 核心工程组

运行模式： 物理隔离 / 100% 纯本地

适配架构：x86_64 / ARM64 / 龙芯 / 麒麟

发布时间：2026 年技术发布版

✦ 执行摘要 (Executive Summary)

随着生成式人工智能向各行各业深度渗透，政务涉密、国防军工、金融核心与高端工业制造领域面临

着前所未有的**「数据主权与物理断网安全」**矛盾：公网大模型存在不可控的敏感资产出域泄密风

险；常规离线工具部署极其繁重、依赖复杂；开源生成式 PPT 方案大多采用不可二次编辑的“图

片拼贴”，且配音视频制作成本高昂。

AI-Client 专为彻底解决上述痛点而生。项目以 **Rust 独立核心引擎（core）**为中枢，深度融合

React 现代化任务工作台（web）与 **Tauri 跨平台桌面壳（desktop）**，全面内嵌 **llama.cpp、**

Python、LibreOffice、Piper 神经网络语音与 FFmpeg 等全套附件运行时（sidecars）。系统

交付即包含完整的开箱即用能力，做到“双击即用、物理断网零依赖、原生矢量 PPTX 自由修改 、

音画同步口播视频一键成片”。

100%

全本地离线运算 • 核心资产零外流

0 配置

内嵌完整工具链 • 用户解压即用

原生矢量

DrawingML 形状排版 • 100% 可自由二次编辑

第一章：产品定位与核心痛点破局

在数字化政务与企业数字化转型进程中，日常办公、政务公文研报、技术方案汇报与培训课件的制作占据了大量专家与业务骨干的宝贵时间。现有市场方案存在四大约束瓶颈：

维度挑战	传统方案 / 在线云端平台劣势	AI-Client 创新解决方案
数据安全与保密	必须联网调用云端 API，核心战略规划、财务数据、未公开技术面临审查与网络监听泄密风险。	**物理级断网安全**：模型权重、向量检索、思维推理与文件生成均闭环在宿主机本地内存。
环境部署与门槛	各类开源 Agent 要求宿主机自行安装配置 Python、Node、CUDA、C++ 编译工具链，报错频繁。	**附件运行时整包自包含**：安装包内置免配 Python 3.10+、LibreOffice、FFmpeg 及 Piper 语音模型。
PPT 呈现与复用	多数 AI 工具输出只读图片或简陋 Markdown，排版凌乱文字堆砌，用户无法进行字号、配色与形状微调。	**原生 DrawingML 矢量排版**：严格控制单页 ≤ 4 条要点，语义自适应匹配四宫格、步骤图、对比卡片等现代版式。
口播视频与宣讲	需人工录制或调用昂贵商业数字人；现有转口播工具死板念读 PPT 页面文字，听感机械无感情。	**现场演讲家级口播引擎**：为每页深度剖析痛点、机制与价值，输出自然生动解说词，离线合成音画同步 MP4。

第二章：总体架构与分层技术设计

AI-Client 采用高内聚、松耦合的**「分层解耦架构」**。核心引擎与表现层彻底分离，既能作为单机桌面软件运行，亦支持在无显示设备的服务器/信创节点中以 Headless 无头模式运行。



AI-Client 分层系统架构全景


表现层 (Presentation Layer)
· React 18 + TypeScript + Vite + Tailwind 现代化响应式工作台
· Tauri v2 原生桌面外壳 (Rust 宿主轻量化绑定，内存开销 < 80MB)
· PWA 渐进式离线应用支持 (支持鸿蒙平板/移动端浏览器脱网安装)
核心引擎层 (Core Engine Layer - Rust Crate)
· 任务状态机 (Task State Machine: Pending → Planning → Running → Awaiting → Finish)
· 自主 Agent 循环 (ReAct 范式: 需求解析 → 任务分解 → 工具调用 → 反思校验)
· 智能步骤合并器 (Step Collapsing Engine: 消除多重同名调用噪音)
· 异常人文化诊断指引 (402 余额不足识别 / 离线直出兜底分流器)
· 模型纳管抽象层 (Provider Trait: Local GGUF / ONNX / OpenAI 兼容端点)
· SQLite 嵌入式事务存储 (rusqlite + 自动模式迁移)



图 2-1：AI-Client 模块分层与附件运行时协同拓扑

2.1 为什么选择 Rust 构建核心引擎?

- **零垃圾回收停顿与极低常驻内存**：相较于 Electron 等重型技术，Rust 核心在维持长时间大模型交互与并发任务调度时，常驻内存仅需几十兆，杜绝卡顿。
- **信创 CPU 架构原生跨平台编译**：基于 LLVM 后端，Rust 能够无缝编译为 x86_64、aarch64 以及龙芯 `loongarch64` 原生机器码，完美契合国产信创战略。
- **强类型安全与进程沙箱管理**：Rust 严格的借用检查器与并发所有权模型，确保在频繁拉起多子进程（llama-server、Python、FFmpeg）时绝无内存泄露与僵尸进程。

第三章：核心功能模块深度解析（图文全览）

3.1 任务驱动型 Agent 执行中枢与智能步骤合并

AI-Client 摒弃了传统大模型客户端“仅仅提供聊天窗口”的单一范式，全面拥抱**「目标驱动的任务工作台」**。用户输入模糊的业务诉求后，Agent 执行引擎会自动开启多阶段推进：

1. **阶段 1/4（需求分析与大纲架构）**：分析材料、拆解逻辑脉络、提炼版式方案；
2. **阶段 2/4（PPTX 原生生成）**：调用 `generate_pptx` 工具生成高质感 16:9 矢量文件；
3. **阶段 3/4（音画同步视频渲染）**：调用 `pptx_to_video` 执行矢量提取、TTS 配音与流媒体合成；
4. **阶段 4/4（交付总结）**：归纳产物清单，提供后续编辑建议。

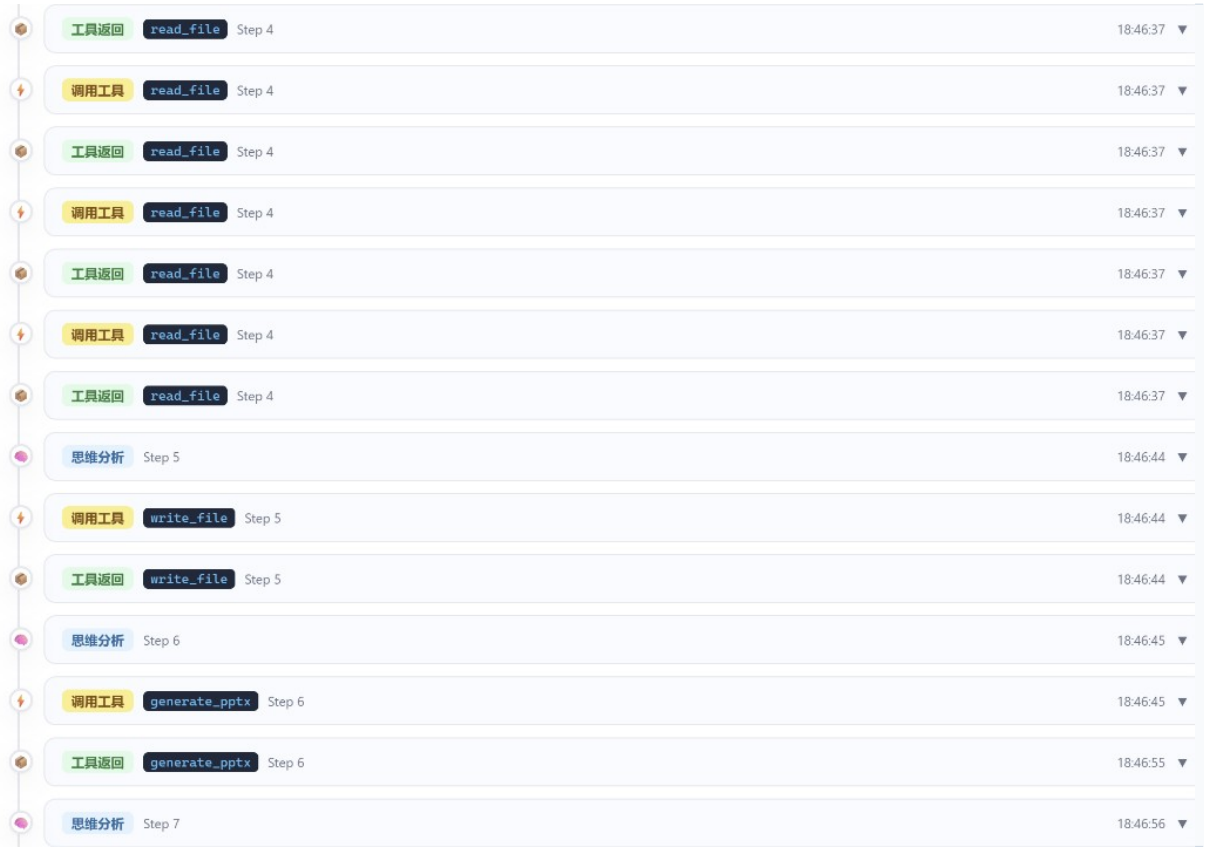


图 3-1：AI-Client 任务执行全景图（展示思维规划、工具调用、状态流转与交付卡片）

✦ **独家创新：相同步骤智能合并算法 (Step Collapsing)**

传统智能体在处理批处理操作或多步重试时，UI 往往被刷入几十条重复的“调用工具”与“工具返回”日志，导致关键业务结论被严重淹没。AI-Client 在前端 `LogViewer` 组件中引入了步骤拓扑折叠机制：对同一 Step 内的连续同名工具操作（如连续调用 `read_file` 或 `write_file`），系统自动将其折叠聚合为一个整洁的状态卡片，并在徽标上实时显示子操作执行计数（如 `read_file (4 次操作)`），既保持极简视觉，又支持点击展开微观调试。

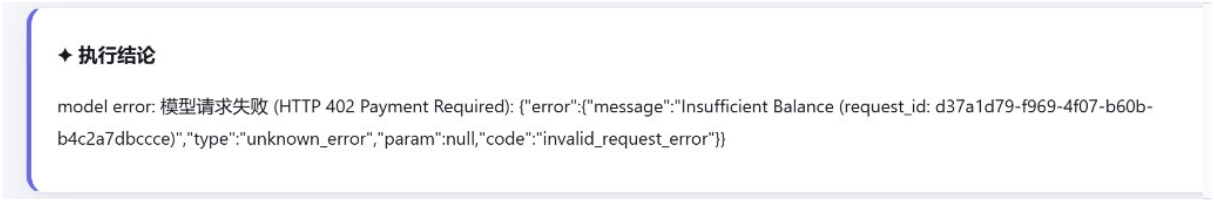


图 3-2：相同步骤合并前后对比与执行状态智能标识

3.2 大模型配置与端侧 llama.cpp 自动化编排

AI-Client 提供了高度弹性、多模态的模型纳管层，覆盖从端侧离线推理到本地自建服务器的全场景：

- **本地 GGUF / ONNX 离线模型导入**：用户仅需在界面指定本地 `.gguf` 文件路径，系统内的 `LlamaServerManager` 将在任务触发时自动探测空闲端口，按需拉起高性能 `llama-server`，任务结束后自动回收显存；
- **本地局域网 OpenAI 兼容端点接入**：支持直接对接内网部署的 Ollama、vLLM、Xinference 等大模型服务；
- **402 余额耗尽人文化诊断与免 API 离线直出**：当配置的外部接口由于账户欠费返回 HTTP 402/401 时，系统不再抛出冰冷的代码异常，而是弹出友好诊断卡片，并提供「⚡ **使用内置离线引擎直接生成 PPT (免 API 额度)**」快捷按钮，确保用户紧急任务不中断。

第四章：ppt-master 演示文稿与口播视频引擎

4.1 原生 DrawingML 矢量排版体系（告别图片拼接与杂乱堆砌）

与市场上大部分“将 HTML/Markdown 截图贴进 PPT”的假课件工具不同，AI-Client 内置的 `ppt-master` 生成的是 **100% 原生矢量 DrawingML 幻灯片**。文档中的每个矩形卡片、圆角高光底板、立体阴影、文本框与字号层级，在 Microsoft PowerPoint、WPS Office 或 LibreOffice 中均可自由选中、移动、换色或修改文字。



图 4-1：ppt-master 演示文稿生成实机效果（层次分明、高对比重点大字、优雅现代）

为彻底解决用户痛感最强烈的“文字堆砌、排版凌乱、主次不分”问题，引擎确立了严格的**排版设计规范**

- **单页要点严格控制在 3~4 条以内**：若原始材料单节超过 4 条，算法自动启用主题分叶（如“核心定位”、“功能全景”、“应用落地”），严禁信息过载；
- **该简介简介，该详细详细**：标题精炼醒目（4~10 字）大字高对比呈现；正文详细展开（20~50 字）把背后的工作机制与价值介绍清楚，严禁粗暴截断关键句；
- **语义感知自适应版式**：
    - **4 条要点** → 触发 **2×2 四宫格聚焦矩阵**（带独立彩条与胶囊徽章）；
    - **3 条要点** → 触发 **三列立体特色卡片**（并列横向架构，带顶部序号圆球）；
    - **2 条要点** → 触发 **左右双栏对比 VS 布局**；
    - **数据亮点** → 触发 **36pt 超大高对比数值亮点卡片**（如 100%、0 门槛、3 倍提升）；
    - **流程推进** → 触发 **横向步骤流转图**（圆标与推进指示箭头）；
    - **金句使命** → 触发 **居中大字极简愿景页。**



四宫格聚焦矩阵 (Quad Grid)



36pt 数据亮点卡片 (Stat Cards)



横向流程步骤图 (Process Steps)



三列立体特色卡片 (Column Cards)

4.2 现场演说家级口播文案与全离线音画合成流水线

传统“PPT 转视频”软件最大的硬伤在于：配音直接念读 PPT 屏幕上干瘪的要点文字，听觉体验僵硬、机械且索然无味。AI-Client 彻底颠覆了这一模式，推行**「屏幕负责要点精简展示，口播负责深度剖析讲解」**的双轨设计：

✦ **演讲家级解说词引擎设计三要素（拒绝机械读 PPT）：**

1. 情境代入与痛点设问：从受众痛点切入（例如：*“聊到技术架构，大家最关心的第一点往往是：在完全断网的环境下，大模型到底能不能跑得顺？我们的答案是不仅能跑，而且能跑出极致体验…”*）；

2. 核心逻辑与机理解剖： 对 PPT 上的要点进行深层次因果分析与商业/技术收益阐发；

3. 生动口语与情感充沛： 使用自然流畅、富有感染力的现场演说口吻，设问与递进结合，文案自动注入 PPT 演讲者备注（Speaker Notes）。

随后，全离线视频流水线自动接力执行：

```
全离线视频渲染四阶段：
PPTX 文件 → [LibreOffice Headless] → 矢量超清 PDF → [PyMuPDF 160DPI 栅格化] → 逐页高清帧图
→ [演讲者备注 → Piper 神经网络语音合成] → 逐页无损音频
→ [FFmpeg 时间戳精确对齐合成] → 高画质音画同步 MP4 视频
```

第五章：插件与技能生态体系 (SKILL.md)

AI-Client 原生兼容开源 **Agent Skill** 规范。系统支持从本地磁盘直接扫描与安装插件，所有启用的插件技能指令与参数规范将自动编译装配至 Agent 系统提示词（System Prompt）中，赋予智能体无限扩展的能力边界。



图 5-1：AI-Client 离线插件与技能中心（支持 SKILL.md 动态导入与运行时自检）

在插件管理中心，系统不仅能够对 `ppt-master` 等预置插件进行状态监控，还提供了**本地附件运行时环境自检仪表盘**，一目了然显示 Python 3.10+、LibreOffice、FFmpeg、llama.cpp 与 Piper 的就绪状态，确保用户在任何极端离线环境下均能掌握系统的健康度。

第六章：国产信创生态与跨平台适配全景

AI-Client 深度响应国产自主可控战略，在架构设计之初即完成了对国内主流软硬件体系的全面适配支持：

体系类别	支持平台 / 架构	适配策略与技术保障
商用通用系统	Windows 10 / 11 (x64), macOS (Intel & Apple Silicon M 系列)	原生 Tauri v2 打包，NSIS 便携安装程序，全自动注册系统关联。
国产信创操作系统	银河麒麟 (KylinOS V10), 统信 UOS, 中科方德	提供 `.deb`、`.rpm` 原生安装包与沙箱便携 AppImage，适配国产桌面环境。
国产信创硬件架构	飞腾 (Phytium/ARM64), 鲲鹏 (Kunpeng/ARM64), 龙芯 (LoongArch64), 海光 (x86)	Rust 核心层支持跨架构源码编译；内嵌 llama.cpp 支持 CPU 纯指令集优化运行。
移动端与泛终端	华为鸿蒙 (HarmonyOS), 统信平板, 移动政务终端	前端集成标准 PWA 离线清单与 Service Worker，支持在断网浏览器内一键固化为本地应用。

第七章：总结与展望

AI-Client 的诞生，代表着企业级 AI 应用从“依赖外部云端公网的玩具型对话”迈向了**“自主可控、全栈闭环、业务强交付的生产力中枢”**。

它不仅守住了政企高安全场景下**数据资产绝不出域**的底线，更在工程细节上实现了**可自由二次编辑的 DrawingML 原生排版**与**极具现场感和感染力的全离线口播视频生成。**未来，AI-Client 将持续演进端侧多模态视觉感知、离线多智能体协同（Teamwork）以及本地语音双向实时对话等前沿能力，为各行各业的数智化建设筑造坚不可摧、高效敏捷的智能基座。

AI-Client 全离线智能体工作站项目组 • 版权所有

文档交付路径：docs/whitepaper/ai_client_whitepaper.pdf | 配套演示：

docs/whitepaper/ai_client_presentation.pptx